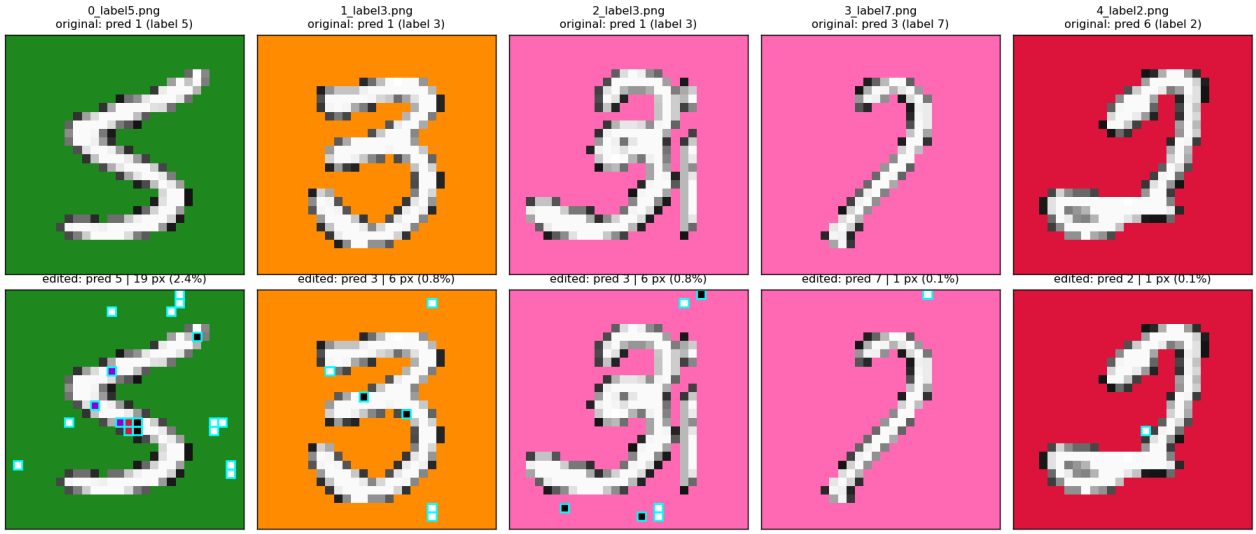
Laboratorio 02 - Reto MNIST: edición mínima guiada por XAI

Autor: Bernardo Ordás Cernadas · **Personas en el grupo:** 1 · Código reproducible en `notebook/challenge.ipynb`

1. Resultado

Imagen	Etiqueta	Pred. original	Pred. editada	Píxeles cambiados	Píxeles conservados	Unidad `fc1` clave (pre-activación)
0_label5	5	1	**5**	19	**97.58 %**	7 (−10.64 → 1.03)
1_label3	3	1	**3**	6	**99.23 %**	3 (−3.93 → 0.48)
2_label3	3	1	**3**	6	**99.23 %**	3 (−3.26 → 0.48)
3_label7	7	3	**7**	1	**99.87 %**	3 (0.61 → 1.30)
4_label2	2	6	**2**	1	**99.87 %**	5 (1.23 → 2.33)

Las 5 imágenes editadas (`data/MNIST/challenge/edited/`) pasan la celda de comprobación del notebook conservando ≥ 97.5 % de los píxeles (mínimo exigido: 60 %).



Originales (arriba) y editadas (abajo); los píxeles cambiados están recuadrados en cian.

2. Diagnóstico: el modelo aprendió un atajo de color

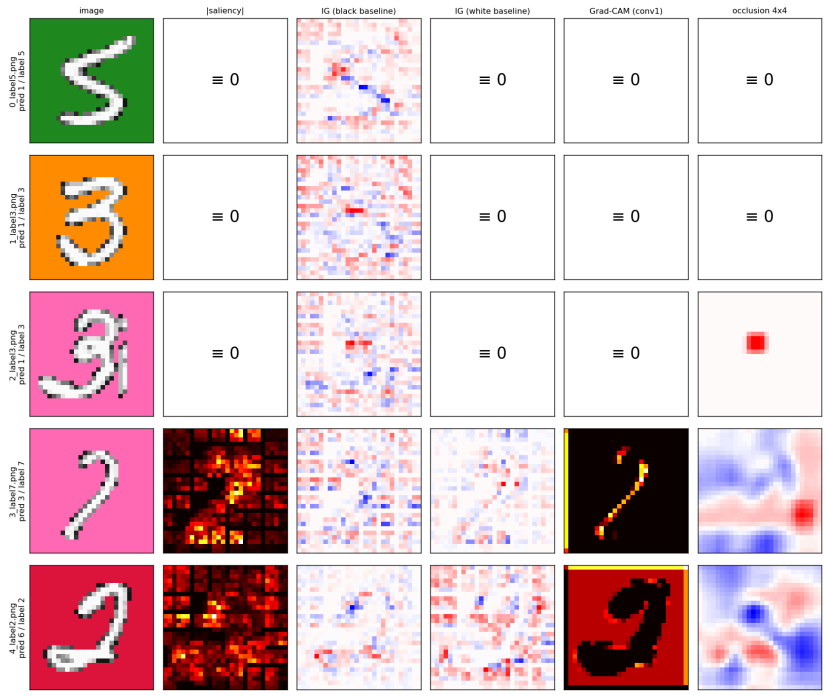
En el conjunto `sample` (10 000 imágenes) cada dígito en gris está sobre un fondo uniforme de 6 colores, y **el color codifica la paridad**: verde/naranja/rosa sólo aparecen con 1-3-5-7-9 y carmesí/azul/violeta con 0-2-4-6-8. El modelo explota esa correlación espuria: acierta el 95 % en fondos "pares" y sólo ~50 % en "impares", donde casi únicamente predice 1, 7 o 9. **El 5 se predice 2 veces en 10 000** (recall 0 %) y el 3 tiene un recall del 2 %. El reto contiene precisamente un 5, dos 3, un 7 y un 2.

3. Insights XAI

Mapas de atribución (saliency, Integrated Gradients, Grad-CAM, oclusión). En las imágenes 0, 1 y 2 saliency, Grad-CAM e IG con base blanca son *idénticamente cero* y la oclusión 4×4 apenas cambia nada. Además, las tres dan exactamente la misma distribución de probabilidad: el modelo es "ciego" a ellas y los gradientes no sirven para guiar la edición. En la 4, Grad-CAM de la clase 2 se concentra en el **fondo** y no en el trazo. En la 3, la oclusión muestra que zonas sin trazo cambian la decisión: es una frontera muy frágil.

Análisis de neuronas (`fc1`, 12 unidades).

- 7 de las 12 unidades no se activan nunca. Las unidades 5, 7, 9 y 11 son **detectores de "fondo par"**: sólo se activan sobre fondos carmesí/azul/violeta (≤ 0.1 % de las veces en fondos impares), su pre-activación es muy negativa con colores con mucho verde (verde, naranja, rosa… y blanco) y en `fc2` penalizan todas las clases impares.
- En fondo impar, en la práctica, sólo puede activarse la **unidad 3**. El 57 % de las veces no hay ninguna activa y la salida es el sesgo de `fc2`, cuyo máximo es "1": es lo que pasa en las imágenes 0, 1 y 2.
- **Ventanas de activación** (deducidas de `fc2` con una única unidad activa): gana el **3** si $a_3 \in (0.29, 0.96)$ y el **7** si $a_3 \in (0.96, 4.24)$. La imagen 3 tiene $a_3 = 0.61$, y por eso sale 3. El **5 es inalcanzable con la unidad 3**: necesita una activación *moderada* de una unidad "par" ($a_7 \in (0.83, 2.55)$ o $a_{11} \in (0.62, 2.04)$), que penaliza más al 1 y al 3 que al 5. El modelo sólo dice "5" si la imagen parece *un poco* par.



Mapas de atribución respecto a la etiqueta correcta (IG: rojo a favor, azul en contra; oclusión: caída del logit). En 0, 1 y 2 los métodos de gradiente son idénticamente cero.

4. Método de edición

Como la salida es plana, en lugar del gradiente se usa la **pre-activación** (antes de la ReLU) de la unidad que indica el análisis anterior. (1) *Despertar la unidad*: en cada paso se prueban todos los cambios de un píxel (784 posiciones × 8 colores: los 6 fondos, blanco y negro) y se aplica el que más sube su pre-activación, lo que equivale a una oclusión exhaustiva a nivel de neurona. (2) *Margen*: en cuanto la salida reacciona, se maximiza logit(etiqueta) − máx(resto) hasta 0.05. (3) *Poda*: se revierten los píxeles que sobran. Para cada imagen se prueban las unidades vivas que tienen ventana para su clase y se elige la edición con menos píxeles.

5. Por qué funciona cada edición (leave-one-out sobre la unidad clave)

- **0 → 5:** 19 píxeles (puntos blancos sobre el fondo y píxeles violeta/carmesí/negro sobre el trazo) repartidos por 22 de las 49 celdas de max-pooling. Como cada celda 4×4 sólo transmite su máximo, basta un píxel por celda. La unidad 7 pasa de −10.64 a 1.03, dentro de su ventana para el 5.
- **1, 2 → 3:** 6 píxeles llevan a_3 a 0.48, dentro de la ventana del 3. La mayor contribución entra por la celda (6, 4) de la fila inferior, donde la unidad 3 tiene sus pesos positivos más altos.
- **3 → 7:** un único píxel blanco en el borde superior, en la celda (0, 4) donde la unidad 3 tiene un peso alto, sube a_3 de 0.61 a 1.30 > 0.96.
- **4 → 2:** un único píxel blanco junto al trazo sube la unidad 5 de 1.23 a 2.33. Su peso en `fc2` favorece al 2 frente al 6 en +0.78, y el margen pasa de −0.05 a +1.00.

Cada píxel editado aporta entre +0.27 y +1.35 a la pre-activación de la unidad clave. **Robustez:** las predicciones se mantienen con aritmética bf16 (más gruesa que el TF32 de las GPU) y en 200 ensayos con un 0.2 % de ruido en los pesos.

6. Conclusión

El reto se resuelve con 1–19 píxeles porque el modelo no reconoce formas: usa un atajo de color, y en buena parte del espacio de entrada todas sus ReLU están apagadas. La pista clave fue precisamente que los métodos de gradiente dieran cero, porque eso obligó a analizar neuronas y pesos y a deducir qué patrón de activación produce cada clase. En la práctica las ediciones son ejemplos adversariales: para una persona las imágenes no cambian. Para corregir el modelo habría que romper la correlación color–paridad (fondos aleatorios, aumentación de color o entrada en gris) y evitar las unidades muertas.